Fondements

ElasticStack, DataOps et le projet SciPulse

Michel Cadennes - mars 2026

DataOps

Pourquoi DataOps ?

Dette de la donnée

La dette de données, l'équivalent data de la dette technique logicielle. Et tout comme le monde du développement a répondu à sa dette technique avec DevOps, le monde de la donnée a besoin de DataOps.

Dette de données

- Pipelines fragiles en production
- Manque de traçabilité des données
- Retards & inefficacité
- Etc.

Définition DataOps

Association des pratiques Agile et de DevOps, appliquées au cycle de vie des données

Le terme a été formalisé en 2018 par le dataopsmanifesto.org, qui s'inspire directement du Manifeste Agile et des principes DevOps.

Ce que DataOps n’est pas

- DataOps n’est pas un outil, mais un ensemble de pratiques
- Ce n’est pas uniquement DevOps
- ≠ MLOps, qui prend en compte de cycle de vie des modèles prédictifs

Les 3 piliers

Automatisation

Principe : tout ce qui peut être automatisé doit l'être. Un pipeline exécuté manuellement est un pipeline qui tombera en panne un vendredi soir.

- Infrastructure as Code (Docker, Ansible)
- CI/CD (Github Actions, Jenkins)
- Orchestration (Airflow)

Observabilité

Principe : on ne peut pas améliorer ce qu'on ne mesure pas. Un pipeline de données est une boîte noire tant qu'on ne l'instrumente pas.

- Logs
- Métriques
- Alertes
- Qualité des données

Collaboration

Principe : les silos entre équipes (data engineers, data scientists, analystes, ops) sont l'ennemi de la vélocité.

- Git
- Docs auto
- Environnements reproductibles

Cycle de vie des données

Cycle de vie des données

CRISP-DM

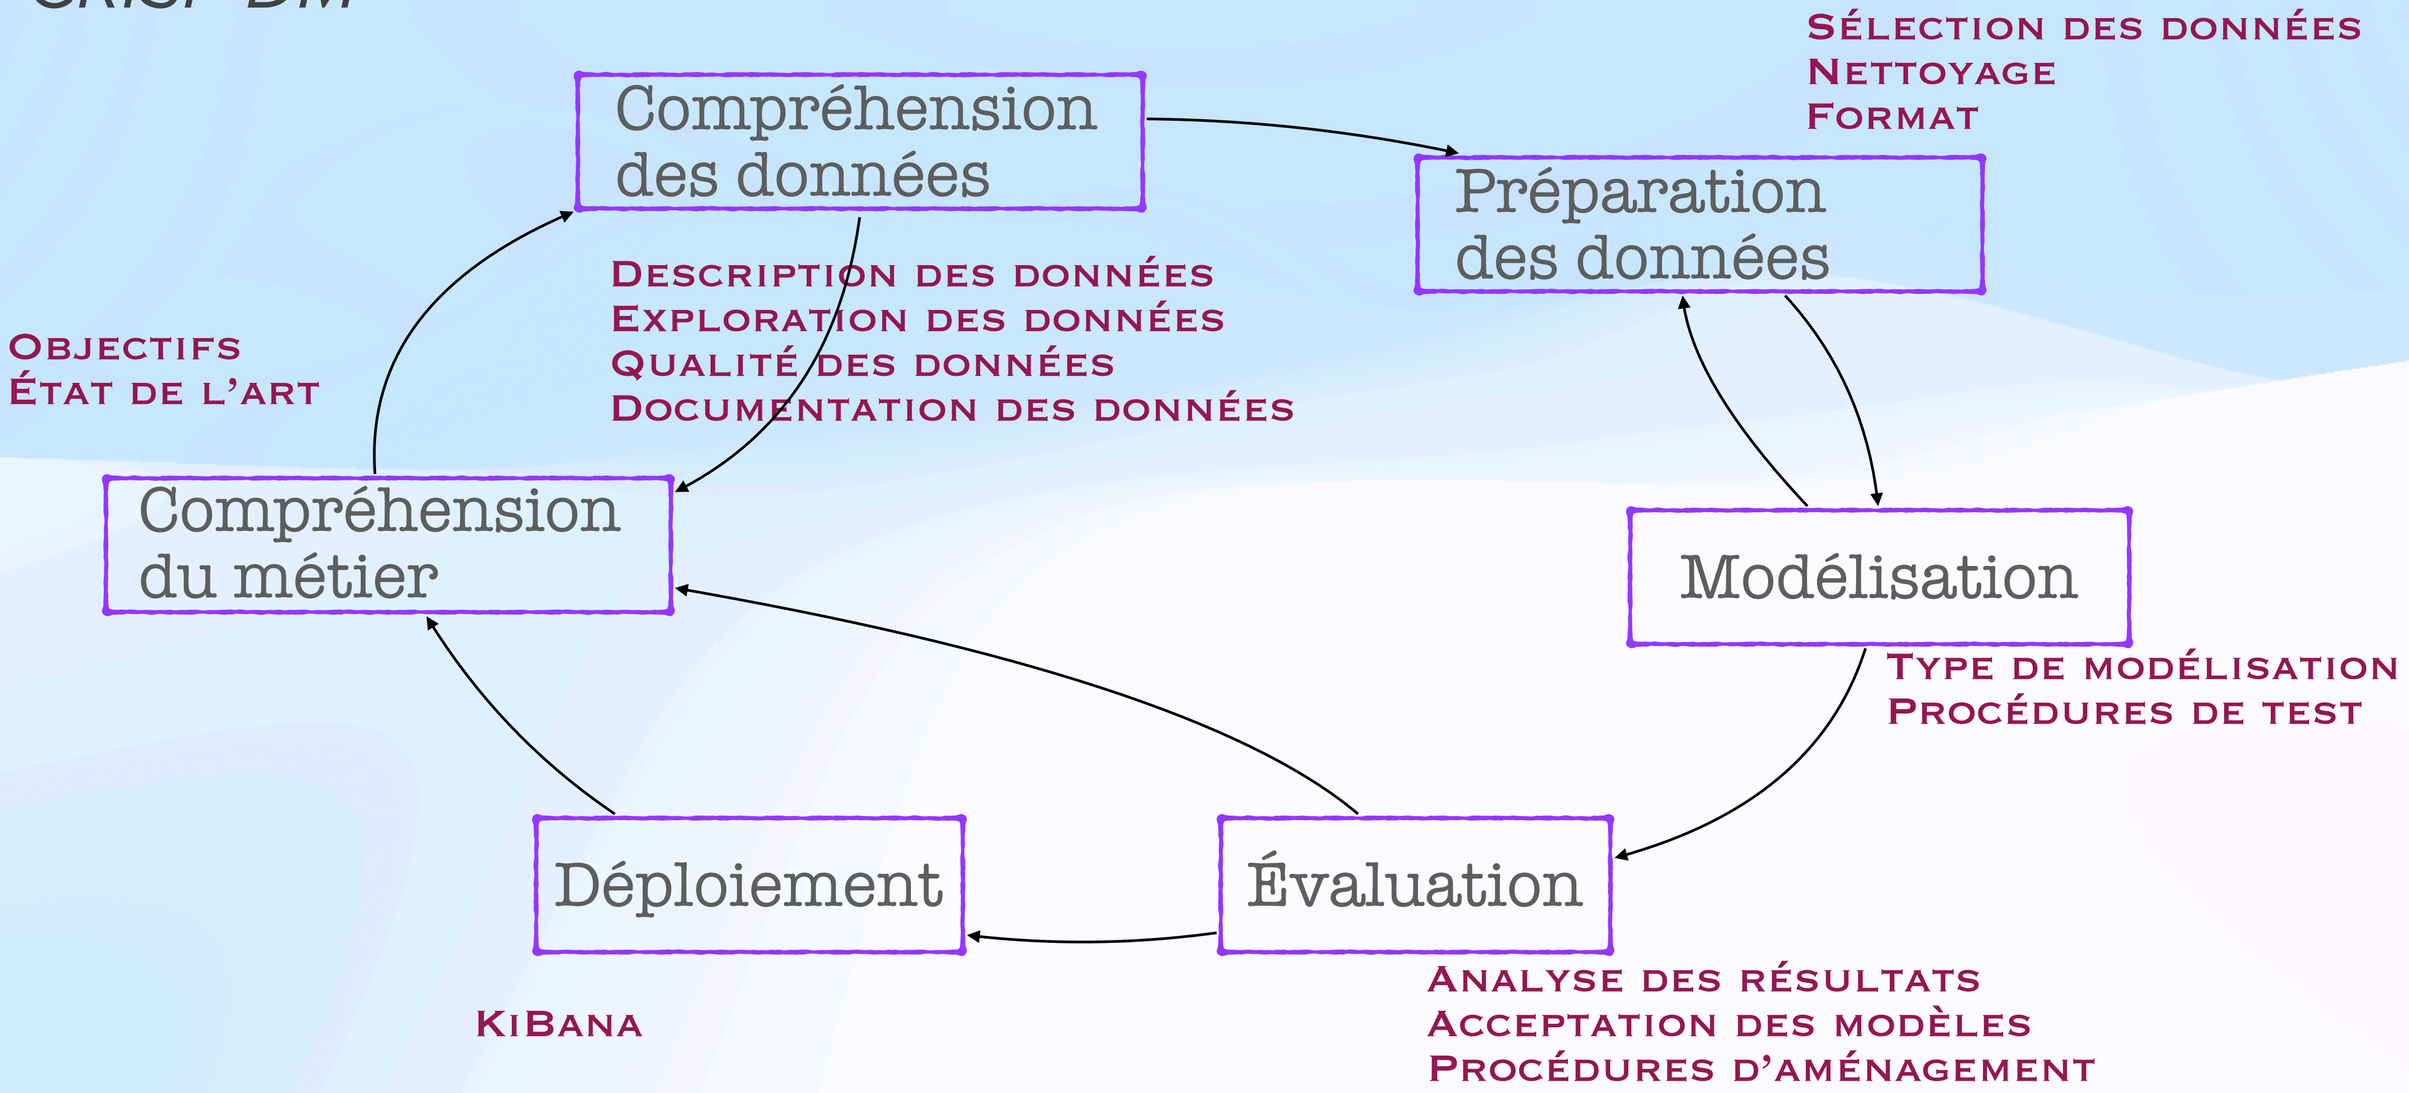

Cycle de vie des données

DataOps

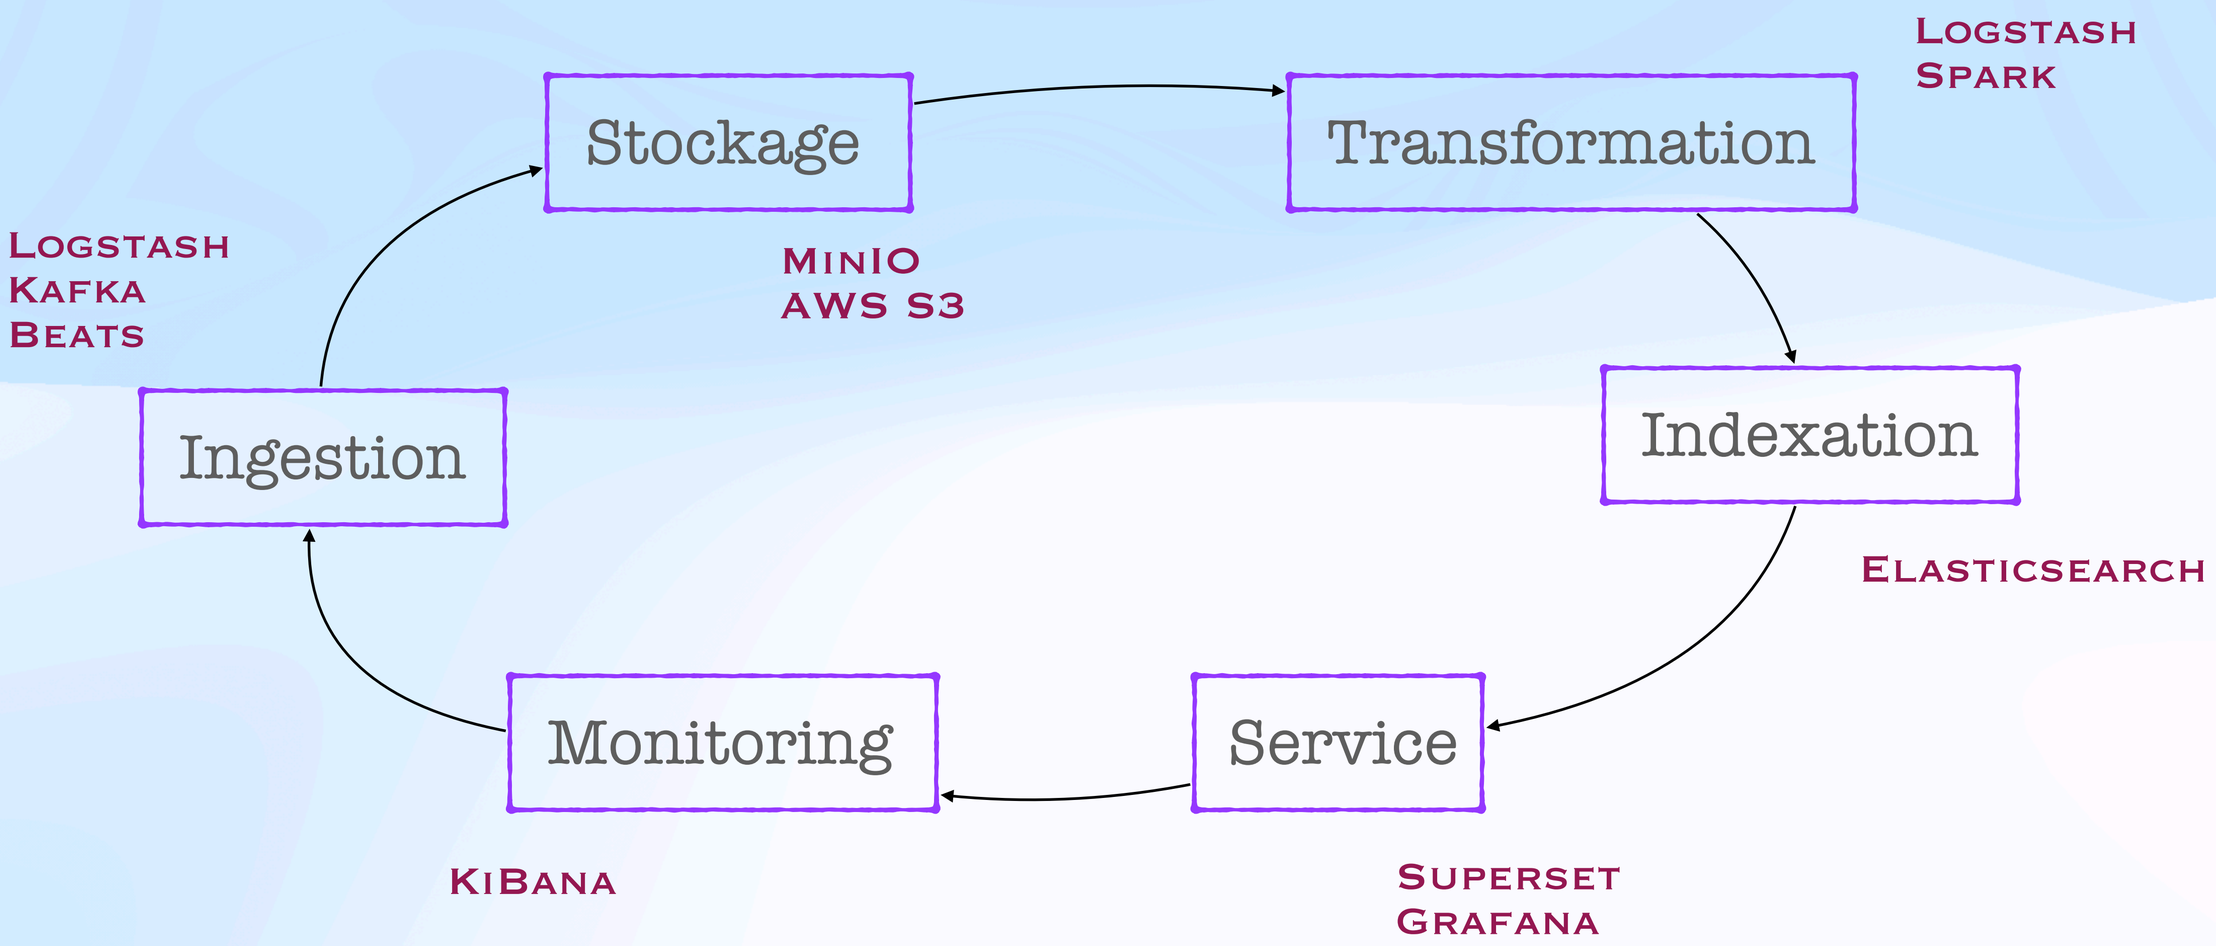

Ingestion

Quoi : collecter les données depuis les sources et les amener dans le système.

Bonne pratique : toujours conserver les données brutes (raw) dans une zone séparée. On ne transforme jamais en place — on crée une copie enrichie. C'est le principe d'immutabilité des données sources.

Stockage

Quoi : persister les données de manière fiable et accessible.

Bonne pratique : séparer les couches de stockage. Les données brutes ne sont jamais dans la même base que les données transformées. C'est le principe du data lakehouse : un lac de données (MinIO) + un entrepôt structuré (PostgreSQL) + un moteur de recherche (Elasticsearch).

Transformation

Quoi : nettoyer, enrichir, structurer les données pour les rendre exploitables.

Bonne pratique : chaque transformation doit être idempotente — l'exécuter une fois ou dix fois produit le même résultat. C'est ce qui permet de relancer un pipeline en toute sécurité après un échec.

Indexation

Quoi : organiser les données pour permettre des recherches rapides.

Bonne pratique :

Service (ou self-service)

Quoi : mettre les données à disposition des utilisateurs finaux.

Bonne pratique :

Monitoring

Quoi : surveiller en continu la santé du pipeline et la qualité des données.

Bonne pratique : .

SciPulse

Projet SciPulse

Une plateforme de veille « intelligente » sur la recherche en IA

L'objectif du projet est de constituer une base de référence à partir du corpus d'articles contenus sur le site de pré-publication ArXiv, ainsi que des dépêches publiées sur le site Hacker News, afin de pouvoir faire de la fouille de texte (*text mining*) et d'extraire les données utiles à diverses tâches (recherche, rapports, etc.)

ArXiv

Points d’intérêt

- Les **abstracts** sont des blocs de texte de 100 à 500 mots
  — parfaits pour la fouille de texte Elasticsearch.
- Les **catégories** sont hiérarchiques :
  — cs.AI = Computer Science > Artificial Intelligence.
  Un article peut avoir plusieurs catégories.
- Les **auteurs** sont une chaîne de texte brute qu'il faudra parser et normaliser.
- La **date** permet des analyses temporelles sur 30 ans de publications.

Hacker News

Points d’intérêt

- Le champ `url` peut contenir un lien vers un article ArXiv
  → enrichissement croisé.
- La relation `kids` (commentaires d'un post) permet d'explorer les relations parent-child dans Elasticsearch.
- Le `score` et `descendants` sont des métriques de popularité
  → function_score pour pondérer la pertinence.
- Le `type` peut être `story`, `comment`, `job`, `poll`
  → facettes et agrégations.