Modélisation

Michel Cadennes - mars 2026

Elasticsearch

Elasticsearch est un moteur de recherche et d'analytique distribué, construit au-dessus de la bibliothèque **Apache Lucene**. Contrairement à une base de données relationnelle, Elasticsearch est conçu pour répondre à deux types de questions :

- Recherche : « quels documents correspondent le mieux à cette requête ? »
  → pertinence, scoring, ranking.

- Analytique : « combien de documents par catégorie ? quelle est la moyenne de ce champ ? »
  → agrégations, statistiques.

Elasticsearch

Comme base de données

Ce n'est pas une base relationnelle : pas de JOIN au sens SQL, pas de transactions ACID strictes, pas de schéma rigide.

Elasticsearch suit plutôt un modèle orienté document, auquel un schéma de document peut être ajouté

Elasticsearch

Comme système de stockage

Ce n'est pas un système de stockage primaire : il est conçu pour la recherche, pas pour être la source de vérité. En architecture DataOps, les données brutes vivent dans MinIO ou PostgreSQL ; Elasticsearch est une couche de serving.

Elasticsearch

Vs. Data lake

Ce n'est pas un data lake : il s'attend à des données structurées (ou semi-structurées avec un mapping).

Index inversé

L’index inversé, paradoxalement, correspond à ce que l’on appelle couramment « index » dans un livre. Il permet une recherche très rapide, à condition que les termes (ou tokens) soient correctement analysés.

Structures de données

- L’index inverse pour la recherche
- Les « doc values » pour les tris et agrégations
- Les « stored fields » pour l’attribut _source

Concepts fondamentaux

Index

Un index Elasticsearch est une collection de **documents** qui partagent une structure similaire. C'est l'équivalent approximatif d'une table en SQL, mais avec plus de souplesse.

- **Nom** : le titre de l’index (minuscules par convention)
- **Mapping** : la définition de la structure des documents
- **Settings** : la définition des modalités de recherche

Document

Un document est l'unité de base d'Elasticsearch : un objet JSON indexé dans un index. Chaque document a comme attributs :

- _id : unique au sein de l'index
- _source : le contenu de l'objet JSON, stocké dans ES
- _index, _score, _version : des métadonnées associées au document

Mapping

Le mapping est la définition de la structure d'un index : quels champs existent, quel est leur type, et comment ils sont analysés. C'est l'équivalent du `CREATE TABLE` en SQL, mais plus riche parce qu'il inclut la configuration d'analyse textuelle.

- Dynamic mapping : quand on indexe un document sans avoir défini de mapping, ES devine les types.
- Explicit mapping (déclaratif) : on définit le mapping avant d'indexer le premier document. C'est la bonne pratique en production.

Types de champs

Text	Le type `text` est conçu pour la recherche en langage naturel.
Keyword	Le type `keyword` stocke la valeur telle quelle, sans analyse. Il est optimisé pour le filtrage exact
Date	Le type `date` accepte plusieurs formats (séparés par `||`).
Integer, long float, double	Pour les métriques numériques.
nested	maintient l'indépendance de chaque objet du tableau en les stockant comme des documents internes séparés
join	établit une relation parent-enfant entre des documents du <u>même index</u>.
completion	optimisé pour les suggestions en temps de frappe (typeahead)

Les analyseurs

Calcul de score

Administration