Ingestion et collecte de données

Michel Cadennes - mars 2026

Ingestion

Définition

L'ingestion est le processus par lequel les données sont collectées depuis des sources hétérogènes et acheminées vers un système de stockage ou de traitement. C'est la porte d'entrée du pipeline

Contraintes initiales

- Formats hétérogènes (CSV, JSON, XML, logs non structurés, binaires).
- Débits variables (un dump quotidien de 3 Go vs. un flux continu de 500 événements/seconde).
- Sources instables (API avec rate limiting, fichiers déposés manuellement, bases de production sous charge).
- Données de mauvaise qualité dès l'origine (encodages cassés, champs manquants, doublons).

Modes d’ingestion

Traitement par lots

Principe

Les données sont collectées en bloc à intervalle régulier.
Le traitement s'applique à l'intégralité du lot d'un coup.

Traitement par lots

Caractéristiques

- Latence élevée : minutes à heures entre la production et la disponibilité.
- Volumétrie par exécution potentiellement très grande (Go à To).
- Traitement prévisible et planifiable.
- Gestion des erreurs simple : en cas d'échec, on relance le lot entier.

ⓘ Logstash (plugin `file`)
Apache Spark
Scripts Python + cron

Traitement en flux

Principe

Chaque événement est traité individuellement, dès qu'il se produit. Le système fonctionne en continu, sans notion de lot.

Traitement en flux

Caractéristiques

- Détection de fraude en temps réel.
- Monitoring d'infrastructure (métriques serveur, alertes).
- Systèmes de recommandation en temps réel.
- IoT (capteurs, télémétrie).

① Logstash (mode pipeline)
Apache Kafka
Apache Pulsar
Apache Flink

Traitement en micro-lots

Principe

Les données sont collectées en petits lots très fréquents.

Traitement par micro-lots

Caractéristiques

- Polling d'une API REST à intervalle régulier.
- Collecte de logs toutes les 30 secondes.
- Synchronisation incrémentale entre systèmes.
- Agrégation de métriques à la minute.

① Logstash (plugin `http-poller`)
Filebeat
Apache Spark Structured Streaming (micro-batch natif)

Mécanismes d'ingestion

Alternatives en fonction de la situation

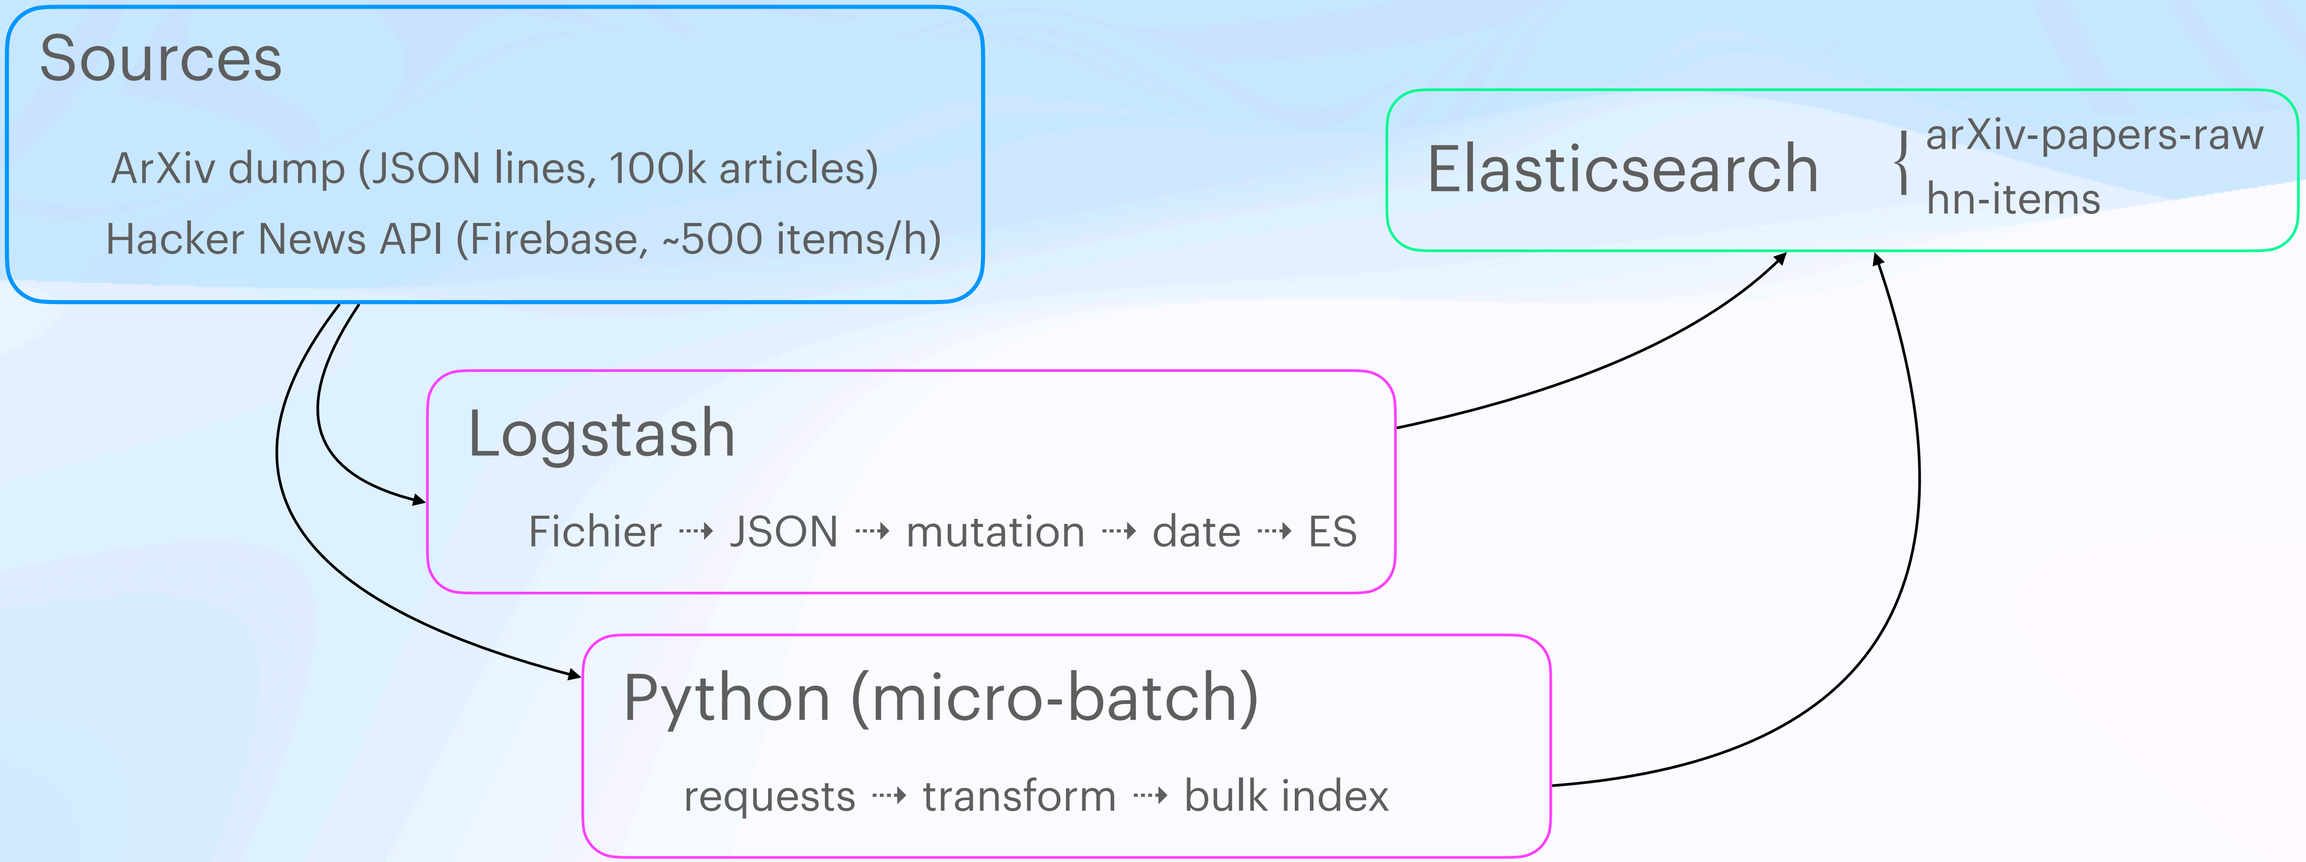

Logstash

Logstash

Définition

Logstash est un moteur de collecte et de transformation de données open-source, développé par Elastic. Il fait partie de la pile ELK (Elasticsearch, Logstash, Kibana), renommée « Elastic Stack » depuis l'ajout de Beats.

Initialement conçu pour la collecte de logs, d'où son nom.

Points forts

- Parser et transformer des données hétérogènes sans écrire de code (configuration déclarative).
- Gérer nativement plus de 200 plugins d'entrée, de filtre et de sortie.
- Garantir la livraison des données (persistent queues).
- Gérer le « *backpressure* » (ralentir l'ingestion si la destination est saturée).

Points faibles

- Consommation mémoire élevée
  (JVM, minimum 512 Mo, recommandé 1 Go).
- Transformations complexes
  (au-delà du parsing, un script Python est souvent plus lisible).
- Scalabilité horizontale
  (pas de distribution native — il faut déployer plusieurs instances).

Pipeline

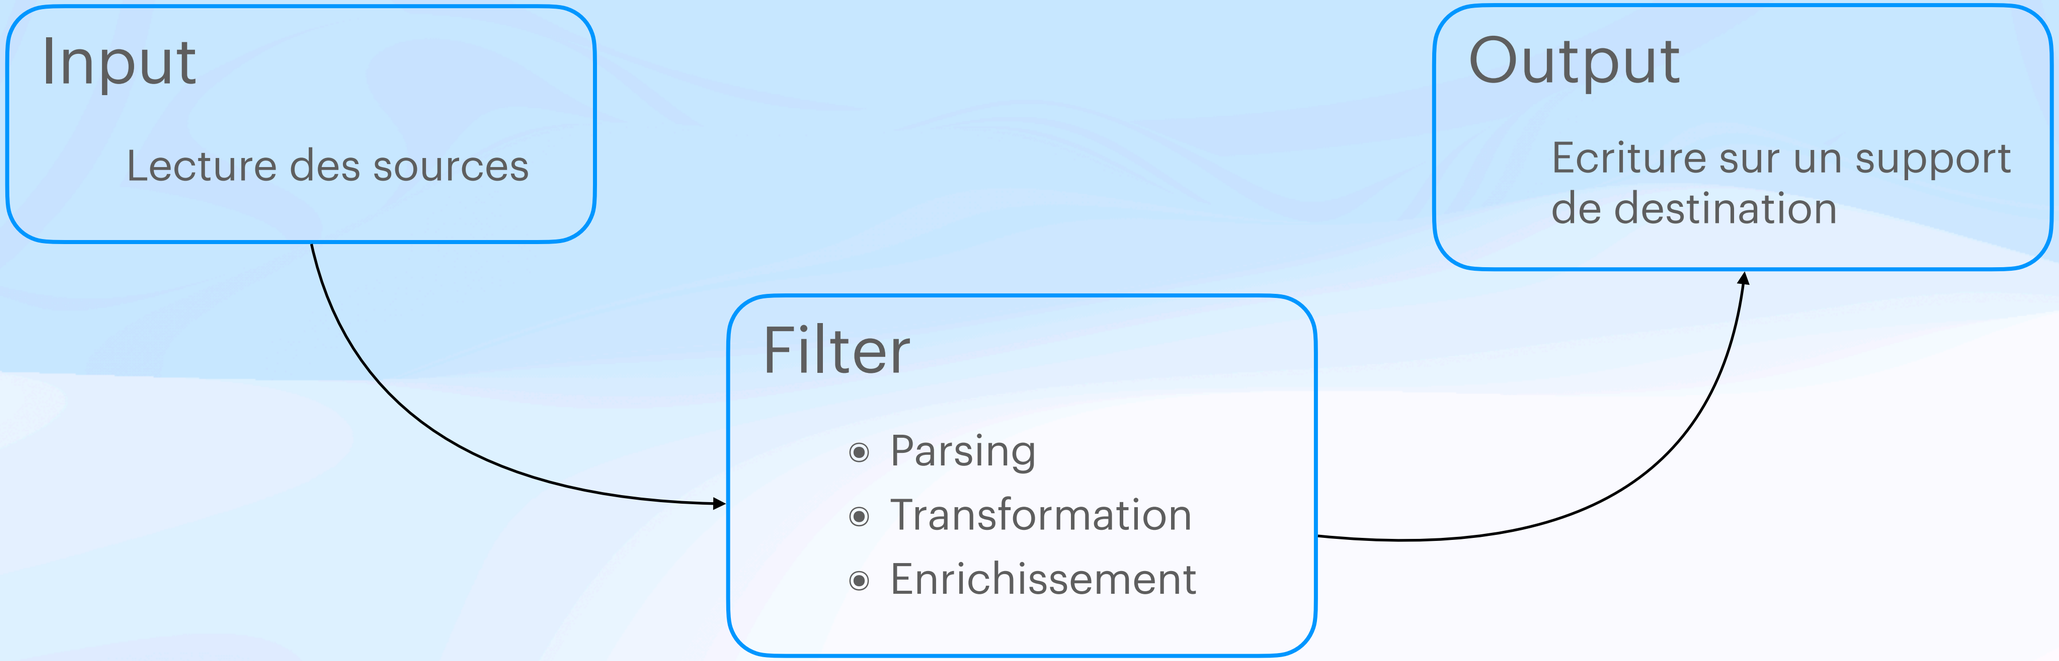

Chaque étape est composée de plugins configurables.
Un pipeline Logstash est défini dans un fichier `.conf` qui déclare ces trois blocs.

Implémentation

Squelette d'un fichier arXiv.conf

arxiv.conf

```
input {
   file {
      ...
      }
}

filter {
   mutate {
      ...
      }
}

output {
   elasticsearch {
   ...
   }
}
```

Beats

Beats

Définition

Beats est une famille d'outils open-source légers qui collectent des données spécifiques depuis des serveurs ou conteneurs, sans alourdir la machine hôte. Les plus courants incluent **Filebeat** (pour les logs), **Metricbeat** (métriques système) et **Packetbeat** (trafic réseau). Contrairement à Logstash, qui traite les données, Beats se contentent de les envoyer directement à Elasticsearch, ou via Logstash pour une indexation rapide

Architecture

Filebeat

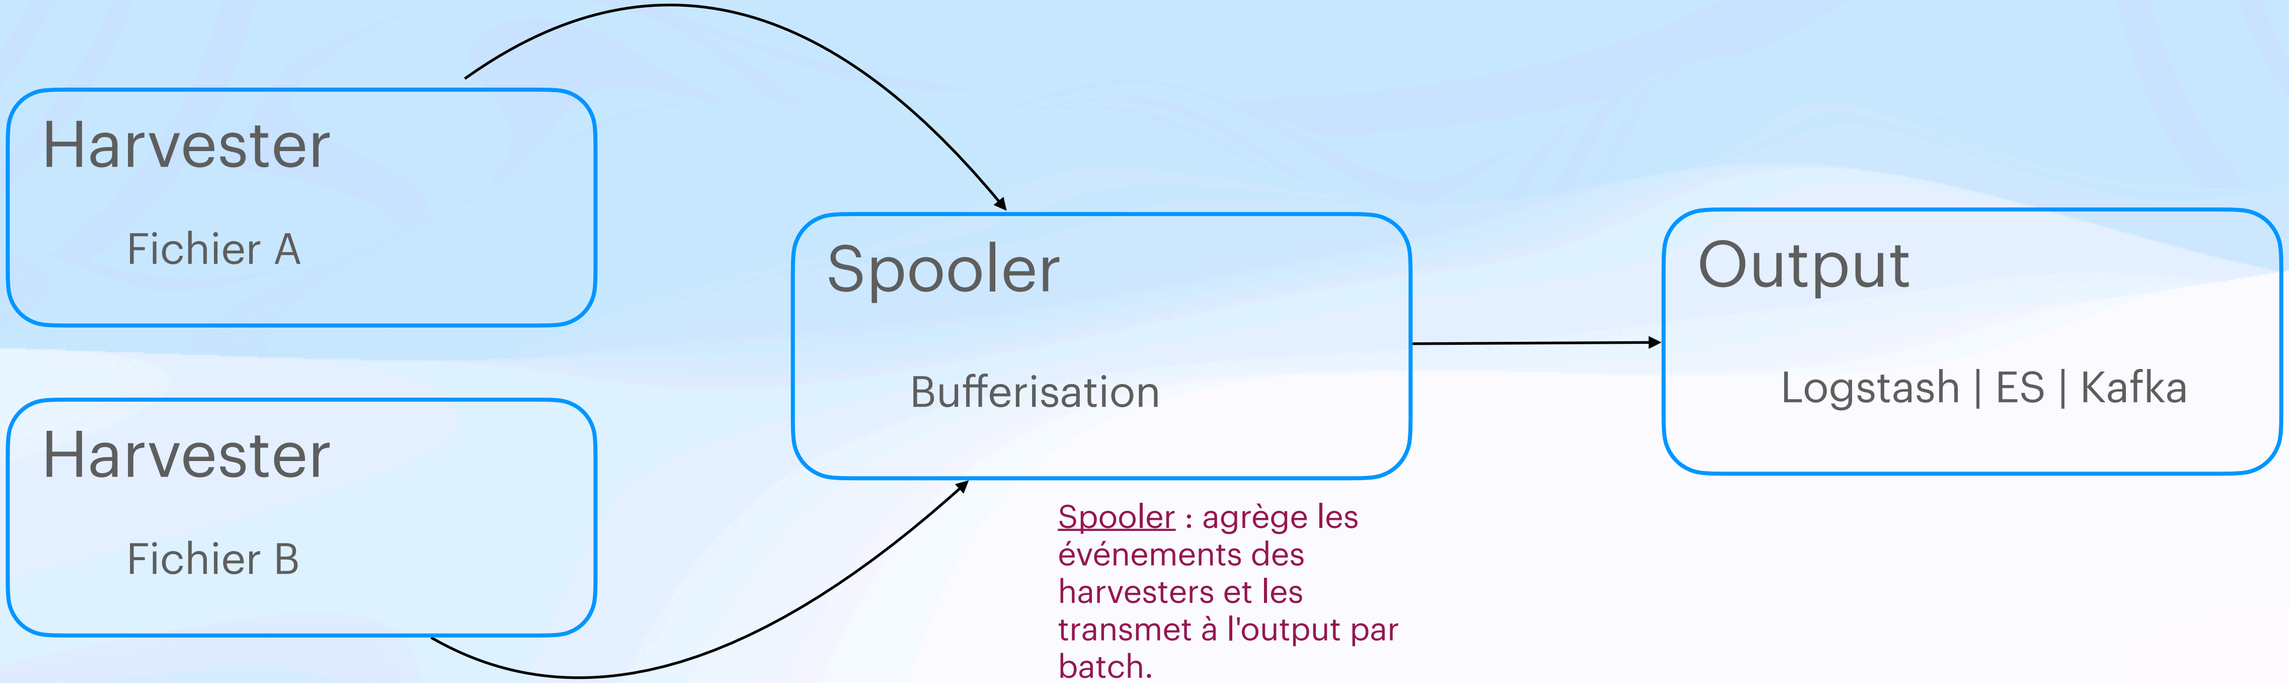

Spooler : agrège les événements des harvesters et les transmet à l'output par batch.

Harvester : Une goroutine par fichier surveillé. Lit les nouvelles lignes et les envoie au spooler. Gère le suivi de position (offset) dans un fichier `registry`.

Registry : fichier persistant qui mémorise la position de lecture de chaque fichier. Survit aux redémarrages. L'équivalent du `sincedb` de Logstash, mais plus robuste.

Point forts

Architecture Filebeat + Logstash

- Séparation des responsabilités : Filebeat s'occupe de la collecte fiable, Logstash du parsing intelligent.
- Scalabilité : on peut ajouter des serveurs (et donc des Filebeat) sans surcharger Logstash grâce au backpressure natif.
- Centralisation du parsing : les règles grok sont à un seul endroit, pas dupliquées sur 200 serveurs.
- Résilience : si Logstash est temporairement indisponible, Filebeat bufferise les événements localement

Bonnes pratiques